

Laporan Machine Learning: Smart City Platform	
Kelompok	3
Nama Ketua	Muhammad Assya Dili
Nama Anggota	• Andito Dwi Wicaksono • Jeremia Marco Namara • Nathasya Herdaningsih • Saif Ali
Prodi	Informatika
Link Repository Github	https://github.com/diliasa12/smart-city-platform.git

BAB I DATASET

Data yang digunakan dalam pengembangan model ini dikumpulkan dalam satu berkas terpusat bernama `smart_ml_dataset.csv`. Dataset ini merepresentasikan rekaman telemetri dari berbagai sensor IoT (Internet of Things) yang ditempatkan di dalam ruangan, mencakup kondisi lingkungan mikro dan penanda waktu.

1.1 Data Dictionary

Dataset ini terdiri dari beberapa fitur utama (*features*) dan variabel target (*labels*) dengan rincian sebagai berikut:

Nama Fitur	Tipe Data	Deskripsi
"temperatur_c"	Float	Nilai suhu ruangan dalam derajat Celcius.
"humidity_pct"	Float	Persentase kelembaban udara di dalam ruangan.
"decibel_level"	Float	Tingkat kebisingan ruangan dalam satuan desibel (dB).
"hour"	Integer	Label waktu dalam format 24 jam

		(0-23).
“is_weekend”	Integer	Penanda untuk menangkap perbedaan pola aktivitas harian (0 = Hari Kerja, 1 = Akhir Pekan).
“ml_classification_status”	String	Label kategori kenyamanan ruangan (nyaman, cukup_nyaman, tidak_nyaman)

1.2 Penggunaan Model

Platform SmartCity ini menjalankan tiga model dari dataset yang akan didistribusikan sebagai berikut:

1. Model Klasifikasi Kenyamanan (Random Forest)
 - a. Input (x): suhu, kelembapan, kebisingan, hour, is_weekend
 - b. Target (y): ml_classification_status
2. Model Prediksi Jam Sibuk (Random Forest Regressor)
 - a. Input (x): suhu, kelembapan, kebisingan
 - b. Target (y): hour
3. Model Deteksi Anomali (Isolation Forest)
 - a. Input (x): suhu, kelembapan, bising, hour
 - b. Target (y): Hanya mengidentifikasi batas skor, seperti -1 untuk anomali dan 1 untuk normal

BAB II Exploratory Data Analysis (EDA)

Proses eksplorasi data difokuskan pada dataset sensor IoT Smart City yang berada dalam folder data/smart_ml_dataset.csv. Dataset ini memiliki total 5.000 baris data dengan 8 kolom yang mewakili telemetri lingkungan dan label kenyamanan. Berdasarkan analisis statistik dasar, fitur suhu menunjukkan rentang operasi yang stabil dengan nilai minimum sebesar 18,1°C dan maksimum mencapai 38.0°C, sementara rata-rata suhunya berada di angka 24,6°C. Fitur kelembaban memiliki rentang dari 29,3% hingga 94,7% dengan rata-rata kelembaban ruangan sekitar 54,1%. Sementara itu untuk decibel level untuk

merekam suara lingkungan memiliki standar deviasi tinggi sekitar 21,5 dB, dari kondisi hening 0,0 dB hingga sangat berisik 98,7 dB.

Analisis korelasi mendeteksi hubungan positif yang kuat antara tingkat kebisingan dengan kelembaban (0,69) dan suhu ruangan (0,68), menyatakan bahwa perubahan termal dan aktivitas ruangan berjalan beriringan dengan naiknya kebisingan. Jam operasional (hour) memiliki korelasi positif di sekitar (0,26 - 0,30) terhadap suhu dan kebisingan yang mencerminkan pola aktivitas harian. Sebaliknya, variabel akhir pekan (is_weekend) berkorelasi negatif lemah yang menandakan penurunan aktivitas pada hari libur.

Pada kolom target klasifikasi (ml_classification_status), distribusi kelas menunjukkan ketidakseimbangan kelas yang cukup wajar:

- Kelas nyaman: 2.998 sampel
- Kelas cukup_nyaman: 1.357 sampel
- Kelas tidak_nyaman: 645 sampel

BAB III PREPROCESSING

Tahapan ini dilakukan untuk memastikan format data dari “smart_ml_dataset.csv” dapat diproses, sehingga sesuai dengan spesifikasi input model dan bebas dari format yang korup.

3.1 Standarisasi Format

a. Penghapusan Spasi Berlebih

Nama kolom dalam file CSV dibersihkan dari spasi berlebih menggunakan fungsi `.str.strip()` pada *Pandas*. Langkah ini mencegah *error* saat pemanggilan nama fitur (misalnya, menghindari kesalahan antara "suhu" dan " suhu").

b. Pengecekan Ketersediaan Fitur

Sistem divalidasi untuk memastikan seluruh kolom(suhu, kelembapan, kebisingan) tersedia sebelum proses *training* dilanjutkan, guna menghindari kegagalan eksekusi (*runtime error*).

3.2 Label Encoding

Algoritma Random Forest memerlukan input numerik baik untuk fitur maupun label target. Namun, kolom “ml_classification_status” pada dataset berformat string, sehingga perlu menggunakan modul “LabelEncoder” dari “scikit-learn” untuk mengonversi label teks menjadi kelas numerik (misalnya, 0,1,2,dll). Untuk objek LabelEncoder disatukan ke dalam bentuk dictionary bersama model utama dan di-dump menjadi satu berkas “comfort_classifier.pkl” agar pada fase deployment (yang di fungsi worker), prediksi numerik bisa diubah kembali menjadi teks bahasa manusia.

BAB IV TRAINING

Sistem training dirancang secara terpisah ke dalam tiga skrip untuk menghasilkan model analitik yang berbeda:

- Comfort Classifier Model (train_comfort_model.py): Memprediksi tingkat kenyamanan ruangan menggunakan Random Forest Classifier ($n_estimators = 100$, $random_state = 42$). Fitur prediksi ini meliputi suhu, kelembapan, kebisingan, hour, dan is_weekend, dengan target yang ditransformasikan dengan LabelEncoder. Data dibagi dengan proporsi 80% data latih dan 20% data uji.
- Busy Hour Model (train_busy_hour_model.py): Melakukan tugas untuk memprediksi nilai target jam tersibuk berdasarkan fitur suhu kelembapan, dan kebisingan. Model dilatih menggunakan algoritma Random Forest Regressor ($n_estimators = 100$, $random_state = 42$) di atas keseluruhan data untuk menangkap pola temporal secara utuh.
- Anomaly Detector Model (train_anomaly_model.py): Mengawasi kualitas sensor secara *unsupervised* untuk mendeteksi pembacaan yang

menyimpang atau rusak. Model ini menganalisis fitur suhu, kelembaban, kebisingan, dan hour secara bersamaan menggunakan algoritma Isolation Forest ($n_estimators = 100$, $contamination = 0.005$, $random_state = 42$).

BAB V CROSS - VALIDATION

Pengujian model dilakukan secara ketat untuk memastikan bahwa algoritma tidak hanya menghafal pola dari dataset “smart_ml_dataset.csv”.

- **Penerapan K-Fold Cross Validation**

Strategi ini menerapkan dataset dibagi secara acak menjadi lima bagian yang sama besar. Model kemudian dilatih menggunakan 4 bagian data dan diuji kemampuannya pada 1 bagian yang tersisa. Strategi ini diulang sebanyak lima kali, sehingga setiap data pernah bertindak sebagai test set. Dengan Strategi ini, dapat nilai rata-rata akurasi dan metrik error yang lebih stabil

BAB VI EVALUATE MODEL

Setiap model dievaluasi dan disimpan dalam format .pkl di folder models/ agar dapat langsung diterima oleh server FastAPI

6.1 Kinerja dan Metrik Evaluasi


- **Comfort Classifier (comfort_classifier.pkl):** Menghasilkan akurasi sebesar 99,60% pada data uji. Tingginya akurasi ini memuktikan adanya batas kemampuan yang tegas antara paramater fisik sensor dengan kelas kenyamanan.
- **Busy Hour Model (busy_hour_model.pkl):** Mengevaluasi performa regresi berdasarkan kecocokan tren waktu harian sesnor terhadap pola temporal historis.
- **Anomaly Detector Model (anomaly_detector.pkl):** Menghasilkan skor keputusan dengan batas kontaminasi 5% untuk menyaring pencilan data sensor yang rusak.

6.2 Mekanisme Pemuatan ke Memori Server

Untuk efisiensi RAM, pemuatan file .pkl sekarang dikonsolidasikan secara internal melalui fungsi di app/api/v1/[endpoints.py](#). Model Comfort Classifier di load satu kali saat startup menggunakan lifespan FastAPI untuk melayani HTTP dan worker RabbitMQ tanpa overhead. Sementara itu model Busy Hour dan Anomaly Detector dimuat secara dinamis melalui fungsi internal untuk langsung disisipkan ke dalam pipeline pemrosesan data sensor asinkron.


BAB VII Diagram Arsitektur

7.1 System Diagram



7.2 Sequence Diagram

- Sequence Diagram S1: IoT Data Ingestion



- Sequence Diagram S2: Auth & Role Access

